多媒體程式設計
Python資料處理函數

Instructor: 馬豪尚

檔案和目錄管理

- OS模組提供取得目錄、建立目錄、刪除目錄、刪除膽案、執行作業系統命令等函式
- os.getcwd: 取得目前的工作目錄
- os.remove: 刪除指定的檔案
- os.path:用以處理檔案路徑和名稱
  - abspath(): 傳回檔案完整的路徑名稱
  - basename(): 傳回檔案指定路徑名稱中, 最後的檔案或目錄名稱
  - dirname(): 傳回指定檔案的完整路徑
  - exists(): 檢查指定的檔案或路徑是否存在
  - split(): 將目標路徑分成目錄路徑和檔案名稱並回傳兩個值
  - Join(path, fname): 組合目錄路徑和檔案名稱成為完整路徑

檔案和目錄管理

- os.walk(): 搜尋指定目錄及其子目錄，會回傳包含三個元素的值，分別為目錄名稱、下一層的目錄名稱以及所有檔案名的串列(list)

檔案和目錄管理

- glob模組: 可以取得指定條件的檔案串列
- glob.glob(“路徑名稱”)
  - 路徑名稱可以明確指定檔案名稱也可以使用”*”萬用字元
  - 例如”os*.py”: 代表列出開頭為”os”結尾為”.py”的檔案
  - “*.py”代表列出所有結尾為”.py”的檔案

檔案開啟

- open函式有8個參數，最常用的是檔案名稱、模式以及編碼，只有檔案名稱不能省略其他都可以省略使用預設值
- f=open(檔案名稱,[, 模式],[, 編碼])
  - open函式會建立一個物件，利用這物件就可以處理檔案
  - close()可以關閉這個物件
- 模式:

r: 讀取(預設)	r+: 可讀寫模式，會從第一行的開頭寫入(覆蓋)
w: 寫入模式，指定檔案不存在時會建立檔案再寫入，檔案若存在會覆蓋	w+:先寫入再讀取，指定檔案不存在時會建立檔案再寫入，檔案若存在會覆蓋
a:附加模式，指定檔案不存在時會建立檔案再寫入，檔案若存在會附加到檔案末端	a+:先讀取再寫入，指定檔案不存在時會建立檔案再寫入，檔案若存在會附加到檔案末端

檔案開啟

- with敘述: with結束後會自動關閉開啟的檔案，就不需要使用close來主動關閉檔案
- with open(“檔案名稱”, 模式) as f

檔案讀寫方法

- read(): 一次讀取全部的文字
- read([size]): 讀取目前指標位置之後指定長度為size的字元
- readlines(): 一次讀取所有列，回傳一個串列
- readline([size]):讀取目前指標位置所在列中指定長度為size的字元，忽略[size]參數即為讀取一整列
- write(str): 將指定字串寫入文件
- writelines(list): 將指定的串列寫入文件

檔案讀寫-編碼

- 一般國際通用的編碼為UTF-8
  - f=open(filename, ‘r’, encoding =‘utf-8’)
- Windows系統的中文檔案編碼預設為ANSI
  - f=open(filename, ‘r’, encoding =‘cp950’)

Python 字串(String)

- 分割與合併
  - s.split(): 默認以空格、換行字元分割字串s，返回列表
  - s.join(seq): 以s為分隔符，將seq中的元素串起來成為一個新的字串

Example

```
S = "Horse-Horse-Tiger-Tiger“
print(S.split('-')) #['Horse', 'Horse', 'Tiger', 'Tiger']
print(S.split('Horse')) #['', '-', '-Tiger-Tiger']

SS = ["HOW", "ARE", "YOU"]
print(' '.join(SS)) # 印出 HOW ARE YOU
print('-'.join(SS)) # 印出 HOW-ARE-YOU
```

Python 字串(String)

- 查找
  - s.find(str): 返回str第一次在字串s中出現的index，若找不到則返回-1
  - s.count(str): 返回str在字串s中出現的次數

Example

```
s = "believe"
print(s.find("lie")) #印出2
print(s.find("le"))  #印出-1
print(s.count("e")) #印出3
```

Python 字串(String)

- 替換
  - s.replace(str1, str2)　將s中的str1替換成str2

Example

```
s1 = "ABBABBAAAB"
print(s1.replace('A','C')) #印出 CBBCBBCCCB
```

Python 字串(String)

- s.lower(): 將字串s裡的字母全部改成小寫
- s.upper(): 將字串s裡的字母全部改成大寫
- s.swapcase(): 將字串s的字母大小寫翻轉
- s.lstrip(): 去除字串s左邊的空格
- s.rstrip(): 去除字串s右邊的空格
- s.strip(): 去除字串s左、右兩邊的空格
- s.center(width)返回一個居中的字串，將左右兩邊填充至長度width

Numpy – 建立ndarray

- Import numpy as np
- array()可以使用list或tuple來建立一維陣列
  - np.array([1, 2, 3, 4]) -List
  - np.array((5, 6, 7, 8)) -Tuple
- dtype 可以設定資料的型態
  - np.array([1, 2, 3, 4], dtype=int)
  - np.array([1, 2, 3, 4], dtype=float)

Numpy – 建立ndarray

- 全部值一樣的陣列
  - zeros()：產生全部為零的陣列
  - ones()：全部為1的陣列
  - empty()：無初始值的陣列
- 等差陣列
  - arange(start, stop, step, dtype=None)：step為等差值
  - linspace(start, stop, num, endpoint=True)：num代表陣列的大小

Numpy – 建立ndarray

- 建立多維陣列
  - listdata = [[1,2,3,4,5],
    [6,7,8,9,10],
    [11,12,13,14,15]]

  np.array(listdata)

Numpy – 建立ndarray

- 隨機數列
  - random.random(size)
  - random.ranf(size)
  - random.sample(size)
  - random.randint(low, high, size)
  - random.normal(loc='loc', scale='scale', size=None)：loc為平均值、scale為標準差

Numpy 陣列屬性

- ndim()：取得陣列的維度數量
- shape()：陣列的形狀
- size()：陣列的數量
- dtype()：資料型態
- itemsize()：陣列中元素的大小(位元組為單位)
- nbytes()：陣列的大小(位元組為單位) 一般來說 nbytes = itemsize * size

Numpy 陣列操作

- reshape(): 改變陣列的形狀
  - np.array([1, 2, 3, 4]) → shape=1*4
  - reshape(2, 2) → shape =2*2

- 串接 x=[1, 2, 3] y=[4, 5, 6]
  - concatenate([x,y])：串接
    - [1, 2, 3, 4, 5, 6]
  - vstack([x,y])：垂直串接
    - [[1, 2, 3], [4, 5, 6]]
  - hstack([x,y])：水平串接
    - [1, 2, 3, 4, 5, 6]

Numpy 陣列操作

- z = np.array([1,2,3,4,5,6,7,8,9])
  - np.split(z,[3,5]) → ([1,2,3],[4,5],[6,7,8,9])
- z = np.array([[1,2,3],[4,5,6],[7,8,9]])

1	2	3
4	5	6
7	8	9

- np.vsplit(z,[2]) →

1	2	3
4	5	6
7	8	9

- np.hsplit(z,[2]) →

1	2	3
4	5	6
7	8	9

Numpy 陣列取值

- 一維陣列

  - a[index]
    - a[0]

  - a[start:end]
    - a[1:5]

    - a[:3]

  - a[start:end:gap]
    - a[1:5:2]

Numpy 陣列取值

› 多維陣列 a= np.arange(1, 17).reshape(4, 4)

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

a[2, 3]

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

a[1:3, 1:3]

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

a[1, 1:3]

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

a[:, 2]

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

Numpy 陣列運算

- a = np.arange(1,10).reshape(3,3)
- b = np.arange(10,19).reshape(3,3)
- 對所有元素都加一個值
  - a+1 →

2	3	4
5	6	7
8	9	10

- 對所有元素取平方
  - a**2 →

1	4	9
16	25	36
49	64	81

1	2	3
4	5	6
7	8	9

a

10	11	12
13	14	15
16	17	18

b

Numpy 陣列運算

- 取出指定陣列的元素進行運算
  - a[0, :] +1 →

2	3	4

- 矩陣相加
  - a+b →

11	13	15
17	19	21
23	25	27

- 矩陣元素相乘
  - a*b →

10	22	36
52	70	90
112	136	162

- 矩陣內積
  - np.dot(a, b) →

84	90	96
201	216	231
318	342	366

Numpy 常用的計算與統計函數

- sum(): 加總
- prod(): 乘積
- mean(): 平均值
- min(): 最小值
- max(): 最大值
- std(): 標準差
- var(): 變異數
- median(): 中位數
- argmin(): 最小元素值索引
- argmax(): 最大元素值索引
- cumsum(): 陣列元素累加
- cumprod(): 陣列元素累積
- percentile(): 以百分比顯示陣列中的指定值
- ptp(): 最大值與最小值的差

Numpy 排序函數

- 一維陣列排序
  - np.sort(): 對陣列中的值進行排序並返回結果
  - np.argsort(): 對陣列中的值進行排序並返回索引值

	45	28	21	47	11	26	30	22	15	16
sort()	11	15	16	21	22	26	28	30	45	47
argsort()	4	8	9	2	7	5	1	6	0	3

Numpy 排序函數

- 多維陣列排序，可以用axis軸來設定排序方式

a

2	4	1	6	2
2	2	4	6	9
5	1	6	0	9

- np.sort(a, axis=0) → 對直行進行排序

2	1	1	0	2
2	2	4	6	9
5	4	6	6	9

- np.sort(a, axis=0) → 對直行進行排序

1	2	2	4	6
2	2	4	6	9
0	1	5	6	9

練習1

- 請將輸入字串中英文字中的母音(aeiou)都去除
  - 假設輸入apple → 印出ppl
  - 假設輸入animal → 印出nml

練習2

- 請產生一個隨機1-4的整數, 6個數字的數列
- 請將這個數列用one-hot encoding的方式來表示
  - 1=[1,0,0,0], 2=[0,1,0,0], 3=[0,0,1,0], 4=[0,0,0,1]

練習3

- 請產生一個隨機0-10整數的5*5二維陣列
- 請把每隔一列(row)且隔一個欄(column)的值取出, 不能用指定位置的方式

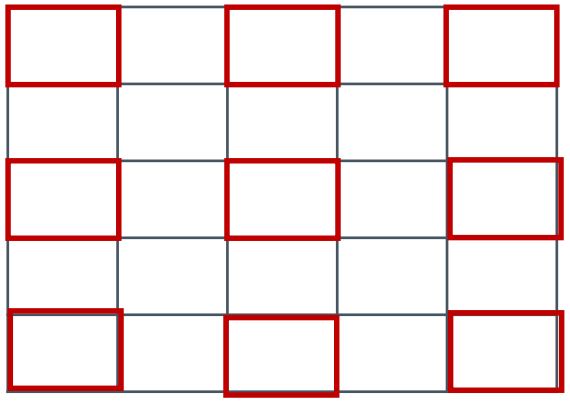

- 請將取出的值, 依照大小從左上角開始, 依序擺放在陣列中
  - 每一列的最左邊為該列最小值, 每一欄最上方也是該欄最小

練習4

- 請讀取一個文件檔, 該文件檔是一篇論文的內容, 請將除了章節標題以外的文字做反序
  - 例如: 我的興趣是打籃球and play piano → onaip yalp dna球籃打是趣興的我